

PSI - Sprawozdanie

Laboratorium nr 2

Opis wykonywanego ćwiczenia

Celem wykonywanego ćwiczenia jest poznanie dwóch nowych typów neuronów: sigmoidalnego i adaline oraz sieci jednowarstwowej złożonej z tych dwóch typów. Zostaną one zaimplementowane oraz przetestowane pod kątem sprawdzania wielkości liter.

Schemat ćwiczenia

1. Zaimplementowanie perceptronu sigmoidalnego
2. Zaimplementowanie ADALINE (**A**daptive **L**inear **N**euron)
3. Zaimplementowanie sieci jednowarstwowej dla obu typów neuronów
4. Uczenie sieci za pomocą danych testujących
5. Sporządzenie tabeli z błędami sieci (MSE)

Wykonanie ćwiczenia

Oba z neuronów zostały zaimplementowane bazując na materiałach dostępnych w książce Stanisława Osowskiego - sieci neuronowe do przetwarzania informacji.

Neuron sigmoidalny jest budową zbliżony do perceptronu, różni się on przede wszystkim funkcją aktywacji i zwracaną wartością. Wykorzystuje on ciągłą funkcję aktywacji: uni- lub bi-polarną. Podczas ćwiczenia wykorzystana została unipolarna funkcja aktywacji w postaci:

$$f(x) = \frac{1}{1 + e^{-\beta x}}$$

Funkcja zmiany wagi różni się też nieco od tej w perceptronie, mianowicie w neuronie sigmoidalnym do obliczenia nowej wagi wykorzystywana jest pochodna funkcji aktywacji.

$$\Delta w_{ij}(k+1) = -\eta \delta_i x_j + \alpha \Delta w_{ij}(k)$$

gdzie:
 i - numer neuronu
 j - numer wejścia
 w - waga
 η - learning rate
 δ - pochodna funkcji aktywacji

$$\delta = \frac{df}{dx} = \frac{e^{\beta x}}{(e^{\beta x} + 1)^2}$$

Adaline działaniem ani budową nie różni się znacznie od perceptronu czy neuronu sigmoidalnego. Funkcją aktywacji jest signum. Jej największą różnicą jest to że wagi nie mają tak jak poprzednie neurony wartości z zakresu $<-1, 1>$, różni się również postać funkcji obliczania błędu.

$$w_{ij}(k+1) = w_{ij}(k) + \eta e_i x_j$$

$$e_i = \left(d_i - \sum_{j=0}^N w_{ij} x_j \right)$$

gdzie:
 d - wektor z oczekiwanymi wyjściami
 e - błąd neuronu

Oba neurony były uczone z nauczycielem.

Do trenowania neuronów posłużył wykonany do ćwiczenia zestaw danych z małymi i dużymi literami w tablicy o wymiarach 5x7. Każdy z neuronów posiadał 35 wejść na te dane. W obu sieciach do rozpoznawania wielkości liter posłużyły po 3 neurony.

Do analizy wyjścia dodany został dodatkowy neuron poza siecią do łatwiejszej weryfikacji czy litera jest duża czy mała.

Podczas trenowania dla każdej epoki liczony był błąd średniokwadratowy. Sieć uczyła się dopóki nie spadł on poniżej wartości 0,001. Wszystkie wyniki zostały załączone w postaci pliku excel.

Wnioski

Na podstawie wyników otrzymanych w trakcie ćwiczenia można stwierdzić że sieć złożona z neuronów adaline uczy się szybciej rozwiązywać problem rozpoznawania wielkości liter. Niemniej jednak może być to twierdzenie mylne albowiem postać wyjść każdej z sieci różni się od siebie. Neuron adaline zwraca jedynie wartość 1 lub -1 zwracanej przez funkcję signum, a neuron sigmoidalny zwracał wartości z przedziału $<0,1>$. Można więc stwierdzić że dokładność rozwiązania, mimo niskiego błędu w sieci z Adaline, jest wyższa w przypadku neuronu sigmoidalnego. Potrzebował on bardzo dużej liczby epok do nauczenia się i spełnienia warunku błędu średniokwadratowego ($< 0,001$). Była to liczba ponad 32 tysięcy epok.

Dobranie odpowiedniego learning rate zmniejszyło skalę problemu czasu uczenia się przez neuron sigmoidalny, dla learning rate równego 0,5 sieć potrzebowała 53 krotnie mniej epok rozwiązując problem z podobną dokładnością co neuron uczony przy learning rate równym 0,01. W przypadku adaline przy learning rate 0,01 potrzebowała zaledwie 30 epok po czym dorównała sieci neuronów sigmoidalnych pod względem błędu średniokwadratowego.

Język programowania python okazuje się być pomocny w realizacji projektów z zakresu sieci neuronowych. Jego prosta składnia oraz bardzo przewidywalny sposób działania umożliwiające szybkie znajdowanie błędów w kodzie oraz logice matematycznej wymaganej do zaimplementowania sieci neuronowych. Pomaga też fakt że jest on językiem skryptowym, tak więc nie wymaga kompilacji, co znacznie przyspiesza sprawdzanie działania programu.

Kod programu

#plik z klasą neuronu sigmoidalnego

#!/usr/bin/python

import random

from math import exp

from sigmoid import Sigmoid

from sign import Sign

import numpy as np

class Perceptron:

def __init__(self, learning_rate, no_of_inputs, activation_function, activation_function_der):

self.__dict__['_no_of_inputs'] = no_of_inputs

self.__dict__['_weights'] = []

self.__dict__['_inputs'] = []

self.__dict__['_learningRate'] = learning_rate

self.__dict__['_activationFunction'] = activation_function

#funkcje aktywacji oraz pochodna zostały

self.__dict__['_activationFunctionDer'] = activation_function_der

#przekazane przez konstruktor

self.__dict__['_bias'] = -1 * np.random.randn()

#ma to służyć uproszczeniu tworzenia kolejnych

self.__dict__['_sum'] = None

#projektów

self.__dict__['_error'] = None

for weight in range(0, self._no_of_inputs):

self._weights.append(random.uniform(-1,1))

#losowanie wag

def guess(self, inputs):

self._inputs = inputs

self._sum = np.dot(self._weights, self._inputs) + self._bias #sumowanie oraz wyznaczanie wektora wejść i wag

return self._activationFunction(self._sum)

def train(self, inputs, desiredOutput):

output = self.guess(inputs)

delta = (desiredOutput - output)

self._error = delta * self._activationFunctionDer(self._sum) #implementacja liczenia błędu dla perceptronu sigmoid.

```

for i in range(len(self._inputs)):
    self._weights[i] += self._error * self._inputs[i] * self._learningRate #dyskretna zmiana wartości wag

self._bias = self._learningRate * self._error #zmiana wartości wagi polaryzacji

return output

```

#plik z funkcją aktywacji perceptronu sigmoidalnego

```

import numpy as np
class Sigm:
    def __call__(self, beta):
        def sigm(x):
            return 1.0/(1.0+np.exp(-beta*x)) #implementacja funkcji aktywacji neuronu sigmoidalnego
        sigm.__name__ += '({0:.3f})'.format(beta)
        return sigm
    def derivative(self, beta):
        def sigmDeriv(x):
            return beta*np.exp(-beta*x)/((1.0+np.exp(-beta*x))**2) #implementacja pochodnej funkcji aktywacji
        sigmDeriv.__name__ += '({0:.3f})'.format(beta)
        return sigmDeriv

```

#plik z adaline

```

#!/usr/bin/python
import random
import numpy as np

class Adaline:
    def __init__(self, learning_rate, no_of_inputs):
        self.__dict__['no_of_inputs'] = no_of_inputs
        self.__dict__['_weights'] = []
        self.__dict__['_inputs'] = []
        self.__dict__['_learningRate'] = learning_rate
        self.__dict__['_bias'] = 1
        self.__dict__['_sum'] = None
        self.__dict__['_error'] = None

        for weight in range(0, self._no_of_inputs):
            self._weights.append(random.uniform(-1,1))

    def guess(self, inputs):
        self._inputs = inputs
        self._sum = np.dot(self._weights, self._inputs) + self._bias
        return self.sign(self._sum) #funkcja przetwarzania nie różni się niczym od funkcji #zaimplementowanej w perceptronie z lab. nr 1

    def train(self, inputs, desiredOutput):
        output = self.guess(inputs)
        self._error = desiredOutput - self._sum #obliczanie błędu Adaline
        for i in range(len(self._inputs)): #uaktualnianie wag odbywa się w ten sam sposób co w #perceptronie
            self._weights[i] += self._error * self._inputs[i] * self._learningRate

        self._bias = self._learningRate * self._error
        return output

    def sign(self, x):
        if x > 0:
            return 1
        else:
            return -1

```

#plik z implementacją sieci jednowarstwowej (wspólny dla obu typów neuronów)

```

#!/usr/bin/python

from perceptron import Perceptron

```

```
from testinput import TestInput
```

```
class SingleLayer:
```

```
    def __init__(self, no_of_layer, no_of_perceptrons, no_of_inputs, learning_rate, activation_function,
activation_function_der):
```

```
        self.__dict__['_perceptrons'] = []
        self.__dict__['_testInputs'] = []
        self.__dict__['_perceptronOutputs'] = []
        self.__dict__['_activationFunction'] = activation_function
        self.__dict__['_activationFunctionDer'] = activation_function_der
        self.__dict__['_noOfInputs'] = no_of_inputs
        self.__dict__['_learningRate'] = learning_rate
        self.__dict__['_noOfPerceptrons'] = no_of_perceptrons
        self.__dict__['_thisLayerNo'] = no_of_layer
```

```
        for i in range(self._noOfPerceptrons)
```

```
            self._perceptrons.append(Perceptron(self._learningRate, self._noOfInputs, self._activationFunction,
self._activationFunctionDer))
```

```
    def getPerceptron(self, index_of_perceptron):
```

```
        if index_of_perceptron < 0 or index_of_perceptron >= len(self._perceptrons) :
            return None
```

```
        else:
```

```
            return self._perceptrons[index_of_perceptron]
```

```
    def trainPerceptrons(self, inputs):
```

```
        if(self._thisLayerNo != 0):
```

```
            for x in range(0, 200):
```

```
                for inp in inputs:
```

```
                    perceptronCounter = 0
```

```
                    for perc in self._perceptrons:
```

```
                        perc.train(
```

```
                            inp._testArguments[self._thisLayerNo],
```

```
                            inp._testArguments[self._thisLayerNo + 1][perceptronCounter]
```

```
                        )
```

```
                        perceptronCounter += 1
```

```
        mse = 1;
```

```
        epoch = 0
```

```
        while(mse > 0.001):
```

```
            epoch += 1
```

```
            print("Epoch;", epoch, ";", end='')
```

```
            for inp in inputs:
```

```
                perceptronCounter = 0
```

```
                outputs = []
```

```
                for perc in self._perceptrons:
```

```
                    outputs.append(perc.train(
```

```
                        inp._testArguments[self._thisLayerNo],
```

```
                        inp._testArguments[self._thisLayerNo + 1][perceptronCounter]
```

```
                    ))
```

```
                    perceptronCounter += 1
```

```
                mse += self.MSE(outputs, inp._testArguments[self._thisLayerNo + 1])
```

```
            mse = mse/len(inputs)
```

```
            print("MSE;", mse, ";")
```

```
    def guess(self, inputs):
```

```
        self._perceptronOutputs = []
```

```
        for perc in self._perceptrons:
```

```
            self._perceptronOutputs.append(perc.guess(inputs))
```

```
        return self._perceptronOutputs
```

```
    #Mean squared error
```

```
    def MSE(self, result, expected):
```

```
        sum = 0
```

```

    for i in range(len(result)):
        sum += (result[i] - expected[i])**2
    return sum

```

#plik z danymi wejściowymi

#!/usr/bin/python

```
class TestInput():
```

```
    """docstring for TestInput."""
    """
```

```
    Test input is a vector which represents capital and small letters like as in
    5x7 table
    """
```

```
    availableLetters = ['a', 'A', 'b', 'B', 'o', 'C', 'D', 'I', 'F', 'h', 'U', 'K', 'd', 'H', 'c', 'G', 'w'] #dostępne litery
```

```
    def __init__(self, letter):
```

```
        self.__dict__['_testArguments'] = []
        self.__dict__['_letterOfTest'] = letter
```

```
        self.getLetter()
```

```
    def getLetter(self):
```

```
        if self._letterOfTest == 'a':
```

```
            self._testArguments.append([          #wejście dla pierwszej warstwy
                0, 0, 0, 0, 0,
                0, 0, 0, 0, 0,
                0, 0, 0, 0, 0,
                0, 1, 1, 1, 0,
                0, 1, 0, 1, 0,
                0, 1, 0, 1, 0,
                0, 1, 1, 1, 1
            ])

```

```
            self._testArguments.append([ 0, 0, 1])
```

```
            #oczekiwane wyjście pierwszej warstwy/wejście drugiej warstwy
            #wartość oczekiwana dla ostatniego neuronu

```

```
            self._testArguments.append([0])
```

```
        elif self._letterOfTest == 'b':
```

```
            self._testArguments.append([
                1, 0, 0, 0, 0,
                1, 0, 0, 0, 0,
                1, 0, 0, 0, 0,
                1, 1, 1, 1, 0,
                1, 0, 0, 1, 0,
                1, 0, 0, 1, 0,
                1, 1, 1, 1, 0
            ])

```

```
            self._testArguments.append([1, 0, 0])
```

```
            self._testArguments.append([0])
```

```
        elif self._letterOfTest == 'o':
```

```
            self._testArguments.append([
                0, 0, 0, 0, 0,
                0, 0, 0, 0, 0,
                0, 0, 0, 0, 0,
                0, 1, 1, 1, 0,
                0, 1, 0, 1, 0,
                0, 1, 0, 1, 0,
                0, 1, 1, 1, 0
            ])

```

```
            self._testArguments.append([0, 0, 0])
```

```
            self._testArguments.append([0])
```

```
        elif self._letterOfTest == 'w':
```

```
            self._testArguments.append([
                0, 0, 0, 0, 0,
                0, 0, 0, 0, 0,
                0, 0, 0, 0, 0,
                1, 0, 0, 0, 1,
                1, 0, 0, 0, 1,

```

```

        1, 0, 1, 0, 1,
        0, 1, 0, 1, 0
    ])
    self._testArguments.append([1, 0, 1])
    self._testArguments.append([0])
elif self._letterOfTest == 'c':
    self._testArguments.append([
        0, 0, 0, 0, 0,
        0, 0, 0, 0, 0,
        0, 0, 0, 0, 0,
        0, 1, 1, 1, 0,
        0, 1, 0, 0, 0,
        0, 1, 0, 0, 0,
        0, 1, 1, 1, 0
    ])
    self._testArguments.append([0, 0, 0])
    self._testArguments.append([0])
elif self._letterOfTest == 'h':
    self._testArguments.append([
        1, 0, 0, 0, 0,
        1, 0, 0, 0, 0,
        1, 0, 0, 0, 0,
        1, 1, 1, 0, 0,
        1, 0, 1, 0, 0,
        1, 0, 1, 0, 0,
        1, 0, 1, 0, 0
    ])
    self._testArguments.append([1, 0, 0])
    self._testArguments.append([0])
elif self._letterOfTest == 'd':
    self._testArguments.append([
        0, 0, 0, 0, 1,
        0, 0, 0, 0, 1,
        0, 0, 0, 0, 1,
        0, 0, 1, 1, 1,
        0, 1, 0, 0, 1,
        0, 1, 0, 0, 1,
        0, 1, 1, 1, 1
    ])
    self._testArguments.append([0, 0, 1])
    self._testArguments.append([0])

elif self._letterOfTest == 'A':
    self._testArguments.append([
        0, 1, 1, 1, 0,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 1, 1, 1, 1,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1
    ])
    self._testArguments.append([1, 1, 1])
    self._testArguments.append([1])
elif self._letterOfTest == 'B':
    self._testArguments.append([
        1, 1, 1, 1, 0,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 1, 1, 1, 0,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 1, 1, 1, 0
    ])
    self._testArguments.append([1, 1, 1])
    self._testArguments.append([1])

```

```

elif self._letterOfTest == 'C':
    self._testArguments.append([
        0, 1, 1, 1, 0,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 0,
        1, 0, 0, 0, 0,
        1, 0, 0, 0, 0,
        1, 0, 0, 0, 1,
        0, 1, 1, 1, 0,
    ])
    self._testArguments.append([1, 1, 1])
    self._testArguments.append([1])

elif self._letterOfTest == 'D':
    self._testArguments.append([
        1, 1, 1, 1, 0,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 1, 1, 1, 0,
    ])
    self._testArguments.append([1, 1, 1])
    self._testArguments.append([1])

elif self._letterOfTest == 'I':
    self._testArguments.append([
        0, 0, 1, 0, 0,
        0, 0, 1, 0, 0,
        0, 0, 1, 0, 0,
        0, 0, 1, 0, 0,
        0, 0, 1, 0, 0,
        0, 0, 1, 0, 0,
        0, 0, 1, 0, 0,
        0, 0, 1, 0, 0,
    ])
    self._testArguments.append([0, 1, 0])
    self._testArguments.append([1])

elif self._letterOfTest == 'F':
    self._testArguments.append([
        1, 1, 1, 1, 1,
        1, 0, 0, 0, 0,
        1, 0, 0, 0, 0,
        1, 1, 1, 1, 0,
        1, 0, 0, 0, 0,
        1, 0, 0, 0, 0,
        1, 0, 0, 0, 0,
        1, 0, 0, 0, 0,
    ])
    self._testArguments.append([1, 1, 0])
    self._testArguments.append([1])

elif self._letterOfTest == 'G':
    self._testArguments.append([
        0, 1, 1, 1, 0,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 0,
        1, 0, 1, 1, 1,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        0, 1, 1, 1, 0,
    ])
    self._testArguments.append([1, 1, 1])
    self._testArguments.append([1])

elif self._letterOfTest == 'H':
    self._testArguments.append([
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
    ])

```

```

        1, 0, 0, 0, 1,
        1, 1, 1, 1, 1,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
    ])
    self._testArguments.append([1, 1, 1])
    self._testArguments.append([1])
elif self._letterOfTest == 'K':
    self._testArguments.append([
        1, 0, 0, 0, 1,
        1, 0, 0, 1, 0,
        1, 0, 1, 0, 0,
        1, 1, 0, 0, 0,
        1, 0, 1, 0, 0,
        1, 0, 0, 1, 0,
        1, 0, 0, 0, 1,
    ])
    self._testArguments.append([1, 1, 1])
    self._testArguments.append([1])
elif self._letterOfTest == 'U':
    self._testArguments.append([
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        1, 0, 0, 0, 1,
        0, 1, 1, 1, 0,
    ])
    self._testArguments.append([1, 1, 1])
    self._testArguments.append([1])

def makeTestInputs(no_of_tests):          #statyczna funkcja tworząca dane wejściowe
    testInputsArray = []
    x = 0
    for i in range(0, no_of_tests):
        testInputsArray.append(TestInput(TestInput.availableLetters[x]))
        x += 1
        if x == len(TestInput.availableLetters):
            x = 0
    return testInputsArray

```